

AutoML

AutoGluon vs FEDOT

Исследуем другой AutoML, отличный от FEDOT: что он автоматизирует, зачем нужен, какие задачи решает и какими методами выигрывает качество.

research notebook -> presentation

one-line AutoML idea

```
predictor = TabularPredictor(label='target')
model = predictor.fit(train_data, time_limit=100)
predictor.leaderboard(test_data)
```

FOCUS

AutoGluon

Практический AutoML через ансамбли, bagging, stacking и leaderboard.

BASELINE

FEDOT

Сравнение с эволюционным поиском композитных пайплайнов.

AutoML автоматизирует не модель, а весь цикл выбора решения

Это не один алгоритм, а система поиска: preprocessing, выбор модели, гиперпараметры, оценка и ансамбль.



Формально: CASH-задача

Найти пару: алгоритм A + гиперпараметры λ , которые максимизируют метрику M на train/validation.

notebook formula, simplified

```
argmax M(A(lambda), D_train, D_val)
A in model_space
lambda in hyperparameter_space
```

AutoML нужен как ускоритель baseline и страховка от ручного перебора

Он не заменяет DS-эксперта полностью, но снимает самую дорогую рутину: model selection, HPO и первичное сравнение.

Ручной ML	Что дает AutoML
Дни на feature engineering + HPO	Baseline за минуты / часы
Выбор модели часто по привычке	Много моделей проверяются одинаково
Сложно воспроизводить эксперименты	Пайплайн и leaderboard сохраняются
Одна задача съедает много времени	Можно массово прогонять похожие задачи
Эксперт нужен на каждом шаге	Эксперт подключается к улучшению результата

Главная позиция в работе

AutoML - это не магия и не кнопка «сделай ML». Это дисциплинированный поисковик по пространству моделей, пайплайнов и параметров.

Лучшее применение: быстрый сильный baseline + ручная доводка доменной логикой.

Сильная зона AutoML - табличные данные; дальше качество зависит от домена

В новом ноутбуке экспериментальная часть сфокусирована на Breast Cancer и California Housing.

Задача	Реальный пример	Типичная сила
Бинарная классификация	Breast Cancer / Titanic	очень сильная
Регрессия	California Housing	очень сильная
Временные ряды	AirPassengers / M4	средняя-сильная
NLP / текст	reviews, documents	частично
CV / изображения	classification datasets	частично
Anomaly detection	rare / domain-specific	редко

Вывод из notebook

- Табличные задачи - главный полигон AutoML.
- CV/NLP требуют больше доменной настройки.
- Для временных рядов важна специализированная логика split и forecasting-модели.

Для спецзадачи выбран AutoGluon: он принципиально отличается от FEDOT

AutoGluon делает ставку на разнообразие моделей и ансамбли. FEDOT - на поиск структуры композитного пайплайна.

AUTOGLUON

обучить все -> собрать ансамбль

Stacking, bagging, weighted ensemble, leaderboard.

FEDOT

найти структуру pipeline

Эволюционный поиск графа операций и настройка параметров.

ЗАЧЕМ СРАВНИВАТЬ

разные философии AutoML

Не только кто выше по метрике, но почему получился результат.

AutoGluon logic


```
ag_clf = TabularPredictor(  
    label='target',  
    eval_metric='roc_auc'  
)  
.fit(  
    train_data=train_df,  
    time_limit=120,  
    presets='medium_quality'  
)
```

FEDOT logic

```
fedot_clf = Fedot(  
    problem='classification',  
    timeout=120 / 60,  
    metric='roc_auc',  
    with_tuning=True,  
    cv_folds=3  
)
```

AutoGluon выигрывает качество через многоуровневый stacking

Base learners дают out-of-fold предсказания, следующий слой учится на их ошибках, финал собирает weighted ensemble.




Ключевая мысль

AutoGluon не пытается угадать одну идеальную модель. Он строит портфель сильных моделей и комбинирует их ошибки.

Кросс-валидация в AutoGluon встроена в bagging и stacking

Да: CV не просто оценивает модель, а генерирует честные OOF-признаки для следующего слоя.



- Каждая модель обучается на нескольких фолдах.
- На validation-фолде получаются out-of-fold predictions.
- OOF-предсказания становятся признаками для следующего слоя.
- Итог: меньше переобучения и стабильнее ансамбль.

fit call

```
TabularPredictor(...).fit(  
    train_data=train_df,  
    time_limit=TIME_LIMIT,  
    presets='medium_quality'  
)
```

Под капотом - не одна модель, а зоопарк learners

AutoML обучает разные семейства моделей, а затем отбирает/ансамблирует лучшие по метрике.

Gradient Boosting

LightGBM, CatBoost, XGBoost

обычно лучшие на таблицах

Random Forest / Trees

RandomForest, ExtraTrees

стабильные быстрые baseline

Linear

LogisticRegression, Ridge

интерпретируемые простые модели

Neural Networks

MLP, FastAI NN

добавляют ценность на больших данных

KNN / others

KNeighbors, special models

редко лучшие, но расширяют портфель

Notebook observation

Gradient boosting стабильно побеждает на structured/tabular data, а ensemble забирает финальный прирост.

Финальный ноутбук сравнивает AutoGluon и FEDOT на двух табличных задачах

Протокол одинаковый: split 80/20, random_state=42, time limit 120 секунд, CPU-only окружение.

Задача	Датасет	Цель	Метрики
Classification	Breast Cancer	malignant / benign	Accuracy, F1, ROC-AUC
Regression	California Housing	стоимость жилья	MAE, RMSE, R2

Параметр	Значение
Train/Test split	80% / 20%, stratified для классификации
Time limit	120 секунд на каждый фреймворк
Окружение	macOS ARM64, CPU-only, Python 3.11.9
AutoGluon	v1.5.0, preset medium_quality
FEDOT	v0.7.5, cv_folds=3, with_tuning=True

Почему это честнее

- одинаковый train/test split;
- одинаковая метрика внутри задачи;
- одинаковый лимит времени;
- сравнение качества и времени.

Breast Cancer: AutoGluon почти мгновенно дал сильный baseline

FEDOT чуть выиграл ROC-AUC, но AutoGluon выиграл Accuracy, F1 и обучился примерно в 18 раз быстрее.

AUTOGLUON ACCURACY

0.9561

test

AUTOGLUON F1

0.9655

test

AUTOGLUON TIME

7 sec

medium_quality

FEDOT ROC-AUC

0.9954

лучший ROC-AUC

Метрика	AutoGluon	FEDOT	Победитель
Accuracy	0.9561	0.9474	AutoGluon
F1	0.9655	0.9589	AutoGluon
ROC-AUC	0.9937	0.9954	FEDOT
Время	7 sec	125 sec	AutoGluon

Вывод по классификации

AutoGluon быстрее и выше по Accuracy/F1. FEDOT чуть выше по ROC-AUC благодаря структурному поиску.

FEDOT на Breast Cancer нашел составной pipeline с ресэмплингом

Именно здесь видна его сильная сторона: он возвращает не только score, но и структуру решения.

FEDOT final pipeline



Интерпретация

FEDOT добавил resample для баланса классов и два Random Forest уровня. Это объясняет, почему он чуть выиграл ROC-AUC.

GENERATIONS

43

за 120 sec

DEPTH

4

pipeline

FIT TIME

125s

classification

FEDOT from automl_full_5.ipynb

```
pipeline: logit -> logit -> rf -> resample -> rf
```

```
with_tuning=True  
cv_folds=3  
metric='roc_auc'
```

California Housing: на большой табличной регрессии AutoGluon выиграл с отрывом

За тот же лимит времени AutoGluon успел собрать ансамбль бустингов, а FEDOT остановился на простой Ridge-регрессии.

AUTOGLUON R2

0.8605

лучше

FEDOT R2

0.5764

ridge

AUTOGLUON RMSE

0.4276

меньше лучше

FEDOT RMSE

0.7450

меньше лучше

Метрика	AutoGluon	FEDOT	Победитель
MAE	0.2749	0.5332	AutoGluon
RMSE	0.4276	0.7450	AutoGluon
R2	0.8605	0.5764	AutoGluon
Время	120 sec	121 sec	ничья

Почему такой разрыв

California Housing крупнее: 20 640 объектов. AutoGluon собрал ансамбль бустингов; FEDOT за 120 секунд нашел только Ridge.

Итог по ноутбуку: AutoGluon практичнее по baseline, FEDOT интереснее по структуре

На Breast Cancer FEDOT чуть выиграл ROC-AUC; на California Housing AutoGluon выиграл все метрики качества.

Критерий	AutoGluon	FEDOT
Основная идея	Bagging + stacking + weighted ensemble	Эволюционная оптимизация pipeline
Тип результата	Leaderboard моделей + ансамбль	Граф/дерево операций
Breast Cancer	Accuracy/F1 выше, 7 sec	ROC-AUC выше, 125 sec
California Housing	R2=0.8605	R2=0.5764, Ridge
Скорость	очень быстро на малых данных	поиск структуры требует времени
CV / validation	Bagged k-fold + OOF predictions	cv_folds в поиске и tuning
Интерпретация	leaderboard, feature importance	структура pipeline/графа
Гибкость	ниже: фокус на ensemble	выше: можно искать сложные схемы

Коротко: AutoGluon быстрее дает сильный практический baseline. FEDOT может найти конкурентный составной pipeline, но ему нужен запас времени.

Итог: AutoGluon - практический ускоритель качества, FEDOT - конструктор pipeline

Для работы это хороший финал: мы сравнили не только метрики, но и разные подходы к автоматизации ML.

Когда выбирать AutoGluon

- нужен быстрый сильный baseline;
- табличные данные и классические метрики;
- важен leaderboard и понятное сравнение моделей;
- можно позволить себе ансамбль.

Когда выбирать FEDOT

- нужен составной pipeline;
- интересна структура решения, а не только score;
- задача нестандартная или многоэтапная;
- важна гибкость поиска операций.