



Временных ряды в рамках применения фильтра Калмана



Зачем нужно семейство методов Калмана?

- Работа с временными рядами в условиях неопределённости
- Оценивание скрытых (ненаблюдаемых) состояний динамических систем
- Рекурсивная обработка данных в реальном времени
- Объединение модели системы и зашумлённых измерений
- Применения: навигация, слежение, управление, экономика, робототехника, обработка сигналов

Два класса задач временных рядов

Прогнозирование (предсказание):

Оценить будущие значения $y_{t+1}, y_{t+2}, \dots$ по истории $y_1:t$.

Фильтрация (оценивание состояния):

Восстановить текущее скрытое состояние x_t по наблюдениям вплоть до момента t .

→ Фильтр Калмана решает задачу фильтрации, но его идеи применимы и к прогнозу, и к сглаживанию.

Модель пространства состояний

Динамическая система в дискретном времени:

$$\begin{aligned}x_t &= F_t x_{t-1} + B_t u_t + w_t, & w_t &\sim \mathcal{N}(0, Q_t) \\ y_t &= H_t x_t + v_t, & v_t &\sim \mathcal{N}(0, R_t)\end{aligned}$$

$\mathbf{x}_t \in \mathbb{R}^n$ — скрытый вектор состояния

$\mathbf{y}_t \in \mathbb{R}^m$ — наблюдение

H_t — матрица наблюдения

$\mathbf{w}_t, \mathbf{v}_t$ — независимые белые гауссовские шумы

Начальное состояние : $\mathbf{x}_0 \sim \mathcal{N}(\hat{\mathbf{x}}_0, P_0)$

Байесовский взгляд на задачу фильтрации

Наша цель – рекурсивно вычислять апостериорную плотность:

$$p(\mathbf{x}_t \mid \mathbf{y}_{1:t})$$

Две стадии:

1. Прогноз (prediction):

$$p(\mathbf{x}_t \mid \mathbf{y}_{1:t-1}) = \int p(\mathbf{x}_t \mid \mathbf{x}_{t-1}) p(\mathbf{x}_{t-1} \mid \mathbf{y}_{1:t-1}) d\mathbf{x}_{t-1}$$

2. Коррекция (update):

$$p(\mathbf{x}_t \mid \mathbf{y}_{1:t}) \propto p(\mathbf{y}_t \mid \mathbf{x}_t) p(\mathbf{x}_t \mid \mathbf{y}_{1:t-1})$$

Это точное решение общей задачи байесовской фильтрации (теорема Байеса + маргинализация).

Свойства гауссовских распределений

- Гауссовское распределение полностью описывается средним и ковариацией
 - Линейное преобразование гауссовской величины сохраняет гауссовость
 - Условное распределение гауссовских величин – тоже гауссовское
 - Произведение гауссовских плотностей – гауссовская плотность (с точностью до нормировки)
- Все плотности $p(\mathbf{x}_t \mid \cdot)$ остаются гауссовскими!

Вывод калмановского прогноза (prediction step)

Если $p(\mathbf{x}_{t-1} \mid \mathbf{y}_{1:t-1}) = \mathcal{N}(\hat{\mathbf{x}}_{t-1|t-1}, P_{t-1|t-1})$

то с учётом $\mathbf{x}_t = F_t \mathbf{x}_{t-1} + \mathbf{w}_t$

$$\hat{\mathbf{x}}_{t|t-1} = F_t \hat{\mathbf{x}}_{t-1|t-1} + B_t \mathbf{u}_t$$

$$P_{t|t-1} = F_t P_{t-1|t-1} F_t^T + Q_t$$

Это прямое следствие линейного преобразования и суммы независимых гауссовских величин.

Вывод калмановского обновления (update step)

Имеем априорную оценку $\mathcal{N}(\hat{\mathbf{x}}_{t|t-1}, P_{t|t-1})$ и измерение $y_t = H_t \mathbf{x}_t + \mathbf{v}_t$

Используем байесовскую формулу для гауссовых плотностей. Результат:

$$S_t = H_t P_{t|t-1} H_t^T + R_t \text{ (ковариация инновации)}$$

$$K_t = P_{t|t-1} H_t^T S_t^{-1} \text{ (калмановское усиление)}$$

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + K_t (y_t - H_t \hat{\mathbf{x}}_{t|t-1})$$

$$P_{t|t} = (I - K_t H_t) P_{t|t-1}$$

Обоснование оптимальности (матстатистика)

- Если шумы гауссовские, фильтр Калмана – это точный минимизатор среднеквадратической ошибки (MMSE).
- Даже без предположения о гауссовости, если ограничиться линейными оценщиками, фильтр Калмана – лучший линейный несмещённый оценщик (BLUE – по теореме Гаусса-Маркова в динамической форме).
- Инновационная последовательность $\nu_t = y_t - H_t \hat{x}_{t|t-1}$ – белый шум при правильно настроенной модели (критерий качества).

Почему это работает: интуиция

Апостериорная оценка = компромисс между предсказанием модели и реальным измерением

$$\hat{\mathbf{x}}_{t|t} = \hat{\mathbf{x}}_{t|t-1} + K_t(\underbrace{\mathbf{y}_t - H_t\hat{\mathbf{x}}_{t|t-1}}_{\text{новшество}})$$

Если R_t велико (измерения ненадёжны) $\rightarrow K_t$ мало $\rightarrow$ верим модели

Если Q_t велико (модель неточна) $\rightarrow P_{t|t-1}$ велико $\rightarrow K_t$ велико $\rightarrow$ верим измерениям

Физическая интерпретация: объединение двух источников информации об одном и том же состоянии, каждый со своей неопределённостью.

Физическая интерпретация: задача слежения за объектом

Объект движется согласно законам механики.

Состояние: $\mathbf{x}_t = \begin{pmatrix} \text{положение} \\ \text{скорость} \end{pmatrix}$

Модель (постоянная скорость): $\mathbf{x}_t = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \mathbf{x}_{t-1} + \mathbf{w}_t$

$\mathbf{w}_t$ – немоделируемые ускорения, порывы ветра, погрешности линеаризации

Наблюдение: радар измеряет только положение:

$y_t = (1 \quad 0) \mathbf{x}_t + v_t \rightarrow$ Фильтр Калмана восстанавливает и положение, и скорость, даже если скорость напрямую не измеряется!

Поведение коэффициента усиления Калмана

Для одномерного случая (скалярное состояние, прямое измерение):

$$K = \frac{P_{\text{pred}}}{P_{\text{pred}} + R}$$

Если $R \gg P_{\text{pred}}$ (шум измерения огромен) $\rightarrow K \approx 0$ доверяем предсказанию

Если $R \ll P_{\text{pred}}$ (модель сомнительна) $\rightarrow K \approx 1$ доверяем измерению

Физический пример: инерциальный датчик (IMU) быстро накапливает ошибку (QQ), а GPS даёт позицию с постоянным шумом (RR). Фильтр Калмана непрерывно комбинирует их.

Физический смысл ковариационных матриц

$P_{t|t}$ – эллипсоид неопределённости состояния.

Его эволюция – это динамика «доверия»:

- Прогноз: эллипсоид расширяется (растёт неопределённость) + поворот из-за F
- Коррекция: эллипсоид сжимается в направлениях, наблюдаемых сенсором (H)

Пример: измеряется только положение → неопределённость по скорости сжимается косвенно, через динамическую связь.

Зачем нужно семейство методов: нелинейные расширения

Многие физические системы нелинейны:

- Движение снаряда с сопротивлением воздуха
- Маятник, модель робота-манипулятора
- Финансовые модели с волатильностью